

Analisa Keuntungan Perusahaan Berdasarkan Kategori Produk, Lokasi, dan Pelanggan

Mini Project Python 1

Minggu, 6 September 2026

Ahmad Malik Ibrahim

Introduction



Self-Overview

Nama saya Ahmad Malik Ibrahim, saya adalah lulusan jurusan kedokteran yang memiliki minat tinggi pada statistic, analisis, dan matematika. Tujuan saya dalam karir adalah untuk mendapatkan pekerjaan sebagai data analis

Education

- Bachelor of Medicine – UIN Syarih Hidayatullah
- Medical Doctor – UIN Syarif Hidayatullah

Working Experience

1. Independent Logistics Partner (Feb 2020 – May 2025)
At Gojek (Part-Time)
2. General Practitioner Intern (May 2025 – Jan 2026)
at RSUD M. Zein Painan West Sumatra (Internship)
3. General Practitioner (Feb 2026 – Aug 2026)
at Klinik Pratama Pinang Sari 2 (Contract)

Overview Project

Overview Project

Judul Project

Analisis Turnover Rate Suatu Perusahaan

Tujuan

- Mencari tahu tren pergerakan turnover perusahaan
- Menganalisis kinerja karyawan yang mengundurkan diri
- Menyelidiki departemen dan demografi karyawan yang menjadi penyumbang turnover terbesar

Main Project

Table of Content


1. Problem Statement
2. Data Understanding
 - 2.1. Data Exploration
 - 2.2. Insight Data Exploration
3. Data Preparation
 - 3.1. Data Cleaning
4. Data Manipulation and Analysis
5. Insight
6. Recommendation

1. Problem Statement

PROBLEM STATEMENT

printer market and printing volume trend in indonesia 2026

🕒 October 7, 2025 | Posted by: admin | Category: Informasi Terkini | 💬 No Comments



Market Forecast Overview:

According to market analyses (Statista and 6Wresearch), the **printers and copiers market in Indonesia** is projected to experience modest growth in 2026, reflecting broader digital transformation trends:

1. **Growth Rate:** The volume of printers and copiers is expected to grow by **2.4% in 2026**. This indicates a continued, albeit moderate, expansion of hardware deployment.
2. **Market Size Context:**
 - By 2029, the Indonesian market is expected to reach **approximately 3.3 million units**. Back-calculating suggested growth implies that printer volumes in 2026 will be roughly **2.8–3.0 million units**, depending on precise year-on-year adoption.

Sumber : <https://adminkom.org/printer-market-and-printing-volume-trend-in-indonesia-2026/>

PROBLEM STATEMENT

1. Apakah terdapat transaksi kategori tertentu yang menghasilkan kerugian ?
2. Kategori apa yang menghasilkan keuntungan terbesar ?
3. Di mana lokasi dan siapa pelanggan yang membeli kategori dengan keuntungan terbesar ?

2. Data Understanding

Data Understanding

Import Library berupa :

Pandas

Numpy

Sumber = gdrive (https://drive.google.com/drive/folders/1AWksosjsTfN-Y7sukK3GzkImtAqSpf_8)

Nama = Amazon.xlsx

Format = excel

Tujuan = Analisa Hubungan Penjualan dan Keuntungan Perusahaan

Jumlah Baris : 3203

Jumlah Kolom : 10

[3]:	Order ID	Order Date	Ship Date	EmailID	Geography	Category	Product Name	Sales	Quantity	Profit
0	CA-2013-138688	2013-06-13	2013-06-17	DarrinVanHuff@gmail.com	United States,Los Angeles,California	Labels	Self-Adhesive Address Labels for Typewriters b...	14.620	2	6.8714
1	CA-2011-115812	2011-06-09	2011-06-14	BrosinaHoffman@gmail.com	United States,Los Angeles,California	Furnishings	Eldon Expressions Wood and Plastic Desk Access...	48.860	7	14.1694
2	CA-2011-115812	2011-06-09	2011-06-14	BrosinaHoffman@gmail.com	United States,Los Angeles,California	Art	Newell 322	7.280	4	1.9656
3	CA-2011-115812	2011-06-09	2011-06-14	BrosinaHoffman@gmail.com	United States,Los Angeles,California	Phones	Mitel 5320 IP Phone VoIP phone	907.152	4	90.7152
4	CA-2011-115812	2011-06-09	2011-06-14	BrosinaHoffman@gmail.com	United States,Los Angeles,California	Binders	DXL Angle-View Binders with Locking Rings by S...	18.504	3	5.7825

Data Understanding

Deskripsi Kolom :

Order ID	: Kode unik untuk setiap transaksi
Order Date	: Tanggal pelanggan melakukan pemesanan barang
Ship Date	: Tanggal pesanan mulai dikirimkan kepada pelanggan
EmailID	: Alamat email pelanggan yang melakukan transaksi
Geography	: Informasi lokasi pengiriman yang mencakup Negara, Kota, dan Negara Bagian
Category	: Kategori umum dari produk barang yang dibeli
Product Name	: Nama spesifik dan deskripsi detail dari produk yang dibeli
Sales	: Total nilai pendapatan atau omzet dari penjualan produk
Quantity	: Jumlah barang yang dibeli oleh pelanggan
Profit	: Nilai keuntungan bersih yang diperoleh perusahaan dari penjualan produk

Data Exploration

```
[4]: amazon.info() # Untuk mengetahui jumlah baris dan kolom. Mengetahui missing value tiap kolom, nama nama kolom, dan tipe data tiap kolom

<class 'pandas.DataFrame'>
RangeIndex: 3203 entries, 0 to 3202
Data columns (total 10 columns):
#   Column          Non-Null Count  Dtype  
---  -
0   Order ID        3203 non-null   str     
1   Order Date      3203 non-null   datetime64[us]
2   Ship Date       3203 non-null   datetime64[us]
3   EmailID         3203 non-null   str     
4   Geography       3203 non-null   str     
5   Category        3203 non-null   str     
6   Product Name    3203 non-null   str     
7   Sales           3203 non-null   float64 
8   Quantity        3203 non-null   int64   
9   Profit          3203 non-null   float64 
dtypes: datetime64[us](2), float64(2), int64(1), str(5)
memory usage: 605.8 KB
```

- Terdapat 10 kolom
- Dua kolom memiliki tipe data datetime, yaitu Order Date dan Ship Date
- Lima kolom memiliki tipe data string, yaitu Order ID, EmailID, Geography, Category, dan Product Name
- Dua kolom memiliki tipe data float, yaitu Sales dan Profit
- Satu kolom memiliki tipe data integer, yaitu Quantity
- Semua kolom memiliki 3203 baris data, sehingga tidak terdapat missing value
- Tipe data pada semua kolom sudah benar

Data Exploration

	Order Date	Ship Date	Sales	Quantity	Profit
count	3203	3203	3203.000000	3203.000000	3203.000000
mean	2013-05-10 03:06:07.530440	2013-05-14 01:25:25.195129	226.493233	3.828910	33.849032
min	2011-01-07 00:00:00	2011-01-09 00:00:00	0.990000	1.000000	-3399.980000
25%	2012-05-22 00:00:00	2012-05-26 00:00:00	19.440000	2.000000	3.852000
50%	2013-07-22 00:00:00	2013-07-25 00:00:00	60.840000	3.000000	11.166400
75%	2014-05-23 00:00:00	2014-05-27 00:00:00	215.809000	5.000000	33.000400
max	2014-12-31 00:00:00	2015-01-06 00:00:00	13999.960000	14.000000	6719.980800
std	NaN	NaN	524.876877	2.260947	174.109081

- Kolom Order Date, Ship Date, Sales, Quantity, dan Profit memiliki 3203 baris data, sehingga tidak ada missing value.
- Sales memiliki rata rata penjualan sebesar 226,49 dan median sebesar 60,84, sehingga distribusi gaji karyawan cukup luas dan miring ke kanan. Standard deviasi sales sebesar 524,87, sehingga rentang gaji karyawan cukup lebar.
- Quantity memiliki rata rata sebesar 3,82 dan median sebesar 3, sehingga distribusi kuantitas barang cukup dekat dan sedikit miring ke kanan. Standard deviasi quantity sebesar 2,26, sehingga rentang kuantitas barang cukup sempit.
- Profit memiliki rata rata sebesar 33,84 dan median sebesar 11,16, sehingga distribusi keuntungan tidak terlalu luas dan miring ke kanan. Standard deviasi profit sebesar 174,10, sehingga rentang keuntungan cukup lebar.

Data Exploration Inkonsistensi Data

Membuat copy dataset terlebih dahulu. Lalu melakukan eksplorasi
Memeriksa inkonsistensi pada kolom dengan tipe data string

```
[7]: order_id_unique = pd.DataFrame(amazon_copy["Order ID"].unique())
order_id_unique.to_excel("order_id_unique.xlsx") # Ekstrak unique item untuk diperiksa inkonsistensi
order_id_unique.rename(columns={0 : "Order_ID"}, inplace=True)
order_id_unique # Memanggil unique item untuk diperiksa inkonsistensi
```

```
[7]:
```

	Order_ID
0	CA-2013-138688
1	CA-2011-115812
2	CA-2013-161389
3	CA-2011-167164
4	CA-2011-143336
...	...
1606	CA-2014-137421
1607	US-2013-103674
1608	CA-2013-125794

```
[8]: email_id_unique = pd.DataFrame(amazon_copy["EmailID"].unique())
email_id_unique.to_excel("email_id_unique.xlsx") # Ekstrak unique item untuk diperiksa inkonsistensi
email_id_unique.rename(columns={0 : "Email_ID"}, inplace=True)
email_id_unique # Memanggil unique item untuk diperiksa inkonsistensi
```

```
[8]:
```

	Email_ID
0	DarrinVanHuff@gmail.com
1	BrosinaHoffman@gmail.com
2	IreneMaddox@gmail.com
3	AlejandroGrove@gmail.com
4	ZuschussDonatelli@gmail.com
...	...
681	TroyBlackwell@gmail.com
682	DanLawera@gmail.com
683	SungChung@gmail.com

```
[9]: geography_unique = pd.DataFrame(amazon_copy["Geography"].unique())
geography_unique.to_excel("geography_unique.xlsx") # Ekstrak unique item untuk diperiksa inkonsistensi
geography_unique.rename(columns={0 : "Geography"}, inplace=True)
geography_unique # Memanggil unique item untuk diperiksa inkonsistensi
```

```
[9]:
```

	Geography
0	United States,Los Angeles,California
1	United States,Seattle,Washington
2	United States,West Jordan,Utah
3	United States,San Francisco,California
4	United States,Orem,Utah
...	...
165	United States,Twin Falls,Idaho
166	United States,San Clemente,California
167	United States,Dublin,California

```
[10]: category_unique = pd.DataFrame(amazon_copy["Category"].unique())
category_unique.to_excel("category_unique.xlsx") # Ekstrak unique item untuk diperiksa inkonsistensi
category_unique.rename(columns={0 : "Category"}, inplace=True)
category_unique # Memanggil unique item untuk diperiksa inkonsistensi
```

```
[10]:
```

	Category
0	Labels
1	Furnishings
2	Art
3	Phones
4	Binders
5	Appliances
6	Tables
7	Storage
8	Accessories

```
[11]: product_name_unique = pd.DataFrame(amazon_copy["Product Name"].unique())
product_name_unique.to_excel("product_name_unique.xlsx") # Ekstrak unique item untuk diperiksa inkonsistensi
product_name_unique.rename(columns={0 : "Product_Name"}, inplace=True)
product_name_unique # Memanggil unique item untuk diperiksa inkonsistensi
```

```
[11]:
```

	Product_Name
0	Self-Adhesive Address Labels for Typewriters b...
1	Eldon Expressions Wood and Plastic Desk Access...
2	Newell 322
3	Mitel 5320 IP Phone VoIP phone
4	DXL Angle-View Binders with Locking Rings by S...
...	...
1489	Eldon Econocleat Chair Mats for Low Pile Carpets
1490	Universal Recycled Hanging Pressboard Report B...
1491	Ibico Recycled Grain-Textured Covers

Berdasarkan hasil output dan pemeriksaan hasil ekstrak menjadi excel menggunakan AI, tidak terdapat inkonsistensi data seperti kapitalisasi, spasi, dan typo.

Data Exploration

Missing Value

```
[12]: amazonnull = amazon_copy.isnull().sum() # Mencari jumlah missing value
      amazonnullpercentage = amazonnull / len(amazon_copy) * 100 # Mencari persentase missing value

[13]: print(f"Jumlah missing value : \n{amazonnull}")
      print(f"Persentase missing value : \n{amazonnullpercentage}")

Jumlah missing value :
Order ID      0
Order Date    0
Ship Date     0
EmailID       0
Geography     0
Category      0
Product Name  0
Sales         0
Quantity      0
Profit        0
dtype: int64
Persentase missing value :
Order ID      0.0
Order Date    0.0
Ship Date     0.0
EmailID       0.0
Geography     0.0
Category      0.0
Product Name  0.0
Sales         0.0
Quantity      0.0
Profit        0.0
dtype: float64
```

Berdasarkan hasil output, tidak terdapat missing value pada dataset.

Data Exploration

Duplicate Value

```
[14]: duplicate_all = amazon_copy.duplicated().sum() # Memeriksa jumlah duplicate value berdasarkan tiap baris
      percent_duplicate_all = duplicate_all / len(amazon_copy)*100 # Menghitung persentase duplicate value
      print(f"Jumlah Baris yang duplikat = {duplicate_all}")
      print(f"Persentase Baris yang duplikat = {percent_duplicate_all:.2f}%")

Jumlah Baris yang duplikat = 0
Persentase Baris yang duplikat = 0.00%
```

Berdasarkan hasil output, tidak terdapat duplicate value pada tiap baris.

Data Exploration

Outlier

Mengubah kolom dengan tipe data string menjadi integer menggunakan LabelEncoder supaya bisa outlier dapat diperiksa.

```
[15]: from sklearn.preprocessing import LabelEncoder # Memanggil Library untuk LabelEncoder

[16]: le = LabelEncoder()

[17]: '''Membuat LabelEncoder pada tiap Kolom dengan tipe data string'''
amazon_copy["Order_ID_Code"] = le.fit_transform(amazon_copy["Order ID"])
amazon_copy["EmailID_Code"] = le.fit_transform(amazon_copy["EmailID"])
amazon_copy["Geography_Code"] = le.fit_transform(amazon_copy["Geography"])
amazon_copy["Category_Code"] = le.fit_transform(amazon_copy["Category"])
amazon_copy["Product_Name_Code"] = le.fit_transform(amazon_copy["Product Name"])
```

Data Cleaning Outlier

Memeriksa Outlier Dengan Metode IQR

```
'''Membuat Variabel Baru Untuk Mengambil Nama Kolom Dengan Tipe Data Numerikal'''  
kolom_outlier = amazon_copy.select_dtypes(include=["int64", "float64"]).columns
```

```
kolom_outlier
```

```
Index(['Sales', 'Quantity', 'Profit', 'Order_ID_Code', 'EmailID_Code',  
      'Geography_Code', 'Category_Code', 'Product_Name_Code'],  
      dtype='str')
```

```
for i in kolom_outlier :  
    Q1 = amazon_copy[i].quantile(0.25)  
    Q3 = amazon_copy[i].quantile(0.75)  
    IQR = Q3 - Q1  
    lower = Q1 - 1.5 * IQR  
    upper = Q3 + 1.5 * IQR  
    outlier = (amazon_copy[i] < lower) | (amazon_copy[i] > upper)  
    jumlah_outlier = outlier.sum() # Mengetahui jumlah outlier pada kolom  
    persentase_outlier = jumlah_outlier/len(outlier) * 100 # Mengetahui persentase outlier pada kolom  
    print(f"Jumlah Outlier pada Kolom {i} : {jumlah_outlier}")  
    print(f"Persentase Outlier pada Kolom {i} : {persentase_outlier:.2f}%\n")
```

Data Cleaning Outlier

```
Jumlah Outlier pada Kolom Sales : 368  
Persentase Outlier pada Kolom Sales : 11.489228847955042  
  
Jumlah Outlier pada Kolom Quantity : 62  
Persentase Outlier pada Kolom Quantity : 1.9356852950359038  
  
Jumlah Outlier pada Kolom Profit : 465  
Persentase Outlier pada Kolom Profit : 14.51763971276928  
  
Jumlah Outlier pada Kolom Order_ID_Code : 0  
Persentase Outlier pada Kolom Order_ID_Code : 0.0  
  
Jumlah Outlier pada Kolom EmailID_Code : 0  
Persentase Outlier pada Kolom EmailID_Code : 0.0  
  
Jumlah Outlier pada Kolom Geography_Code : 0  
Persentase Outlier pada Kolom Geography_Code : 0.0  
  
Jumlah Outlier pada Kolom Category_Code : 0  
Persentase Outlier pada Kolom Category_Code : 0.0  
  
Jumlah Outlier pada Kolom Product_Name_Code : 0  
Persentase Outlier pada Kolom Product_Name_Code : 0.0
```

- Terdapat 11,5 persen data outlier pada kolom Sales
- Terdapat 2 persen data outlier pada kolom Quantity
- Terdapat 14,5 persen data outlier pada kolom Profit

Data Cleaning

Distribusi Data

Distribusi Data diperiksa menggunakan uji Shapiro-Wilk

```
[33]: from scipy.stats import shapiro
```

```
[34]: statistik = amazon_copy[["Order_ID_Code", "EmailID_Code", "Geography_Code", "Category_Code", "Product_Name_Code", "Sales_Cap", "Quantity_Log", "Profit_Cap"]]  
statistik
```



```
[34]: Index(['Order_ID_Code', 'EmailID_Code', 'Geography_Code', 'Category_Code',  
         'Product_Name_Code', 'Sales_Cap', 'Quantity_Log', 'Profit_Cap'],  
        dtype='str')
```

```
[35]: for x in statistik :  
      stat, p = shapiro(amazon_copy[x])  
      print(f"p value Kolom {x} : {p:.3f}")  
      if p >= 0.05 :  
          print(f"Kolom {x} terdistribusi normal")  
      else :  
          print(f"Kolom {x} tidak terdistribusi normal\n")
```

Data Cleaning

Distribusi Data

```
p value Kolom Order_ID_Code : 0.000
Kolom Order_ID_Code tidak terdistribusi normal

p value Kolom EmailID_Code : 0.000
Kolom EmailID_Code tidak terdistribusi normal

p value Kolom Geography_Code : 0.000
Kolom Geography_Code tidak terdistribusi normal

p value Kolom Category_Code : 0.000
Kolom Category_Code tidak terdistribusi normal

p value Kolom Product_Name_Code : 0.000
Kolom Product_Name_Code tidak terdistribusi normal

p value Kolom Sales_Cap : 0.000
Kolom Sales_Cap tidak terdistribusi normal

p value Kolom Quantity_Log : 0.000
Kolom Quantity_Log tidak terdistribusi normal

p value Kolom Profit_Cap : 0.000
Kolom Profit_Cap tidak terdistribusi normal
```

- Tidak terdapat data yang terdistribusi normal
- Dianjurkan uji statistik menggunakan Mann–Whitney test, Wilcoxon signed-rank test, ataupun Kruskal–Wallis test

Insight Data Exploration

- Tidak ada inkonsistensi data, tipe data pada tiap kolom sudah benar, tidak ada duplicate value, dan tidak ada missing value. Sehingga tidak ada penanganan inkonsistensi data, tipe data, duplicate value, dan missing value.
- Terdapat outlier pada kolom Sales, Quantity, dan Profit. Penanganan yang dapat dilakukan adalah menkonfirmasi ulang kepada pemberi data. Jika data memang benar, maka dapat ditangani dengan transformasi log atau capping.
- Data terdistribusi tidak normal sehingga perlu adanya konfirmasi kepada pemberi data mengenai kualitas data yang diberikan.

3. Data Preparation

Data Cleaning

Penanganan Inkonsistensi Data, Tipe Data, Duplicate Value, dan Missing Value

Tidak ada inkonsistensi data, tipe data pada tiap kolom sudah benar, tidak ada duplicate value, dan tidak ada missing value. Sehingga tidak ada penanganan inkonsistensi data, tipe data, duplicate value, dan missing value.

Data Cleaning Outlier

Penanganan Outlier Kolom Sales dengan Transformasi Capping

```
'''Penanganan Outlier Kolom Sales dengan Transformasi Capping'''
Q1_sales = amazon_copy["Sales"].quantile(0.25)
Q3_sales = amazon_copy["Sales"].quantile(0.75)
IQR_sales = Q3_sales - Q1_sales
lower_sales = Q1_sales - 1.5 * IQR_sales
upper_sales = Q3_sales + 1.5 * IQR_sales

amazon_copy["Sales_Cap"] = amazon_copy["Sales"].clip(lower_sales, upper_sales) # Transformasi Capping kolom Sales ke kolom Sales_Cap
Q1_sales_cap = amazon_copy["Sales_Cap"].quantile(0.25)
Q3_sales_cap = amazon_copy["Sales_Cap"].quantile(0.75)
IQR_sales_cap = Q3_sales_cap - Q1_sales_cap
lower_sales_cap = Q1_sales_cap - 1.5 * IQR_sales_cap
upper_sales_cap = Q3_sales_cap + 1.5 * IQR_sales_cap
outlier_sales_cap = (amazon_copy["Sales_Cap"] < lower_sales_cap) | (amazon_copy["Sales_Cap"] > upper_sales_cap)
jumlah_outlier_sales_cap = outlier_sales_cap.sum() # Mengetahui jumlah outlier pada kolom Sales_Cap
persentase_outlier_sales_cap = jumlah_outlier_sales_cap/len(amazon_copy) * 100 # Mengetahui persentase outlier pada kolom Sales_Cap
print(f"Jumlah Outlier pada Kolom Sales_Cap : {jumlah_outlier_sales_cap}")
print(f"Persentase Outlier pada Kolom Sales_Cap : {persentase_outlier_sales_cap}")

Jumlah Outlier pada Kolom Sales_Cap : 0
Persentase Outlier pada Kolom Sales_Cap : 0.0
```

Outlier kolom Sales berhasil ditangani dengan Capping.

Data Cleaning Outlier

Penanganan Outlier Kolom Quantity dengan Transformasi Log

```
'''Penanganan Outlier Kolom Quantity dengan Transformasi Log'''
amazon_copy["Quantity_Log"] = np.log(amazon_copy["Quantity"]) # Transformasi Log kolom Quantity ke kolom Quantity_Log
Q1_quantity_log = amazon_copy["Quantity_Log"].quantile(0.25)
Q3_quantity_log = amazon_copy["Quantity_Log"].quantile(0.75)
IQR_quantity_log = Q3_quantity_log - Q1_quantity_log
lower_quantity_log = Q1_quantity_log - 1.5 * IQR_quantity_log
upper_quantity_log = Q3_quantity_log + 1.5 * IQR_quantity_log
outlier_quantity_log = (amazon_copy["Quantity_Log"] < lower_quantity_log) | (amazon_copy["Quantity_Log"] > upper_quantity_log)
jumlah_outlier_quantity_log = outlier_quantity_log.sum() # Mengetahui jumlah outlier pada kolom Quantity_Log
persentase_outlier_quantity_log = jumlah_outlier_quantity_log/len(amazon_copy) * 100 # Mengetahui persentase outlier pada kolom Quantity_Log
print(f"Jumlah Outlier pada Kolom Quantity_Log : {jumlah_outlier_quantity_log}")
print(f"Persentase Outlier pada Kolom Quantity_Log : {persentase_outlier_quantity_log}")

Jumlah Outlier pada Kolom Quantity_Log : 0
Persentase Outlier pada Kolom Quantity_Log : 0.0
```

Outlier kolom Quantity berhasil ditangani dengan Transformasi Log.

Data Cleaning Outlier

Penanganan Outlier Kolom Profit dengan Transformasi Capping

```
'''Penanganan Outlier Kolom Profit dengan Transformasi Capping'''
Q1_profit = amazon_copy["Profit"].quantile(0.25)
Q3_profit = amazon_copy["Profit"].quantile(0.75)
IQR_profit = Q3_profit - Q1_profit
lower_profit = Q1_profit - 1.5 * IQR_profit
upper_profit = Q3_profit + 1.5 * IQR_profit

amazon_copy["Profit_Cap"] = amazon_copy["Profit"].clip(lower_profit, upper_profit) # Transformasi Capping kolom Profit ke kolom Profit_Cap
Q1_profit_cap = amazon_copy["Profit_Cap"].quantile(0.25)
Q3_profit_cap = amazon_copy["Profit_Cap"].quantile(0.75)
IQR_profit_cap = Q3_profit_cap - Q1_profit_cap
lower_profit_cap = Q1_profit_cap - 1.5 * IQR_profit_cap
upper_profit_cap = Q3_profit_cap + 1.5 * IQR_profit_cap
outlier_profit_cap = (amazon_copy["Profit_Cap"] < lower_profit_cap) | (amazon_copy["Profit_Cap"] > upper_profit_cap)
jumlah_outlier_profit_cap = outlier_profit_cap.sum() # Mengetahui jumlah outlier pada kolom Profit_Cap
persentase_outlier_profit_cap = jumlah_outlier_profit_cap/len(amazon_copy) * 100 # Mengetahui persentase outlier pada kolom Profit_Cap
print(f"Jumlah Outlier pada Kolom Profit_Cap : {jumlah_outlier_profit_cap}")
print(f"Persentase Outlier pada Kolom Profit_Cap : {persentase_outlier_profit_cap}")
```

```
Jumlah Outlier pada Kolom Profit_Cap : 0
Persentase Outlier pada Kolom Profit_Cap : 0.0
```

Outlier kolom Profit berhasil ditangani dengan Capping.

Data Cleaning

Cek Kembali Tipe Data

```
[32]: amazon_copy.info() # Dapat digunakan untuk cek tipe data
```

```
<class 'pandas.DataFrame'>
RangeIndex: 3203 entries, 0 to 3202
Data columns (total 19 columns):
#   Column                Non-Null Count  Dtype  
---  -
0   Order_ID              3203 non-null  str    
1   Order_Date            3203 non-null  datetime64[us]
2   Ship_Date             3203 non-null  datetime64[us]
3   EmailID               3203 non-null  str    
4   Geography              3203 non-null  str    
5   Category              3203 non-null  str    
6   Product_Name          3203 non-null  str    
7   Sales                 3203 non-null  float64
8   Quantity              3203 non-null  int64  
9   Profit                3203 non-null  float64
10  Transaksi             3203 non-null  str    
11  Order_ID_Code         3203 non-null  int64  
12  EmailID_Code          3203 non-null  int64  
13  Geography_Code        3203 non-null  int64  
14  Category_Code         3203 non-null  int64  
15  Product_Name_Code     3203 non-null  int64  
16  Sales_Cap             3203 non-null  float64
17  Quantity_Log          3203 non-null  float64
18  Profit_Cap            3203 non-null  float64
dtypes: datetime64[us](2), float64(5), int64(6), str(6)
memory usage: 1.3 MB
```

- Tipe data pada masing masing kolom sudah benar
- Tidak ada penanganan lebih lanjut

Dataset Sebelum dan Sesudah Cleaning

- Sebelum cleaning, dataset awal tidak memiliki masalah pada missing value, duplicate value, tipe data, dan inkonsistensi data. Sehingga tidak ada penanganan.
- Namun dataset awal memiliki outlier pada kolom dengan tipe data float dan integer. Pada dataset yang sudah dicleaning, outlier ditangani dengan cara membuat kolom baru berdasarkan hasil dari transformasi log maupun capping dari kolom aslinya. Dataset yang sudah dicleaning sudah memiliki tipe data yang benar.
- Dataset yang sudah dicleaning tidak terdistribusi normal, sehingga jika ingin melakukan uji statistik, dianjurkan uji statistik menggunakan Mann–Whitney test, Wilcoxon signed-rank test, ataupun Kruskal–Wallis test

4. Data Manipulation dan Analisa

Data Manipulation

Jumlah Kerugian Dari Transaksi Yang Merugi Berdasarkan Kategori (Top 5)

```
'''Filtering berdasarkan profit yang kurang dari 0'''
amazon_analisis[amazon_analisis["Profit"] < 0].groupby("Category").agg(
    Total_Kerugian=("Profit", "sum"),
    Total_Sales=("Sales", "sum"),
    Total_Modal=("Modal", "sum")
).sort_values(by="Total_Kerugian", ascending=True).head(5)
```

	Total_Kerugian	Total_Sales	Total_Modal
Category			
Tables	-5956.6671	23883.844	29840.5111
Machines	-5589.1288	4489.554	10078.6828
Bookcases	-4223.6424	8340.532	12564.1744
Chairs	-2390.3805	21361.208	23751.5885
Binders	-2224.9814	2975.385	5200.3664

Saat menghitung transaksi yang rugi, kategori Tables merupakan kategori dengan jumlah kerugian tertinggi, disusul kategori Machines dan Bookcases. Hal ini terjadi akibat jumlah modal lebih besar dari jumlah sales. Apabila hal ini dibiarkan, maka perusahaan akan menanggung kerugian selama kedepan. Sehingga perlunya penetapan nilai sales yang lebih besar dari nilai modalnya

Data Manipulation

Kategori dengan keuntungan tertinggi ke terendah (Top 5)

```
'''Kategori dengan keuntungan tertinggi ke terendah (Top 5)'''
amazon_analisis.groupby("Category").agg(
    Total_Keuntungan = ("Profit", "sum"),
    Total_Kuantitas = ("Quantity", "sum")
).sort_values(by="Total_Keuntungan", ascending=False).head(5)
```

Category	Total_Keuntungan	Total_Kuantitas
Copiers	19327.2351	88
Accessories	16484.5983	1032
Binders	16096.8016	1868
Paper	12119.2364	1702
Phones	9110.7426	1066

Walaupun terdapat transaksi yang rugi, masih terdapat kategori dengan jumlah keuntungan yang besar. Kategori Copiers merupakan kategori dengan keuntungan terbesar dibandingkan kategori lainnya. Namun dikarenakan ini adalah data di tahun 2011 - 2014 dan di tahun sekarang sudah era digitalisasi, maka harus divalidasi kembali apakah terdapat data baru dan apakah kategori Copiers masih menjadi kategori yang memberikan keuntungan terbesar

Data Manipulation

Keuntungan Kategori Copiers Terbesar Berdasarkan Geography (Top 5)

```
'''Keuntungan Kategori Copiers Terbesar Berdasarkan Geography (Top 5)'''
amazon_analisis[amazon_analisis["Category"]=="Copiers"].groupby("Geography")["Profit"].agg(["sum"]).rename(columns={"sum" : "Total_Keuntungan"}).sort_v
```

Geography	Total_Keuntungan
United States,Seattle,Washington	8290.4449
United States,Los Angeles,California	3704.9333
United States,San Francisco,California	2132.9649
United States,Great Falls,Montana	1379.9770
United States,Des Moines,Washington	1151.9793

Copiers memiliki keuntungan terbesar di lokasi United States, Seattle, Washington sebesar 8290.4449. Perbedaan nilai keuntungan ini signifikan jika dibandingkan lokasi lainnya. Lokasi ini memiliki banyak perkantoran dan instansi pemerintah, sehingga mengindikasikan bahwa Copiers banyak terjual di lokasi ini karena banyak kantor dan instansi pemerintah yang masih menggunakan kertas

Data Manipulation

EmailID di United States,Seattle,Washington dengan profit tertinggi dari pembelian Copiers

```
'''EmailID di United States,Seattle,Washington dengan profit tertinggi dari pembelian Copiers'''
amazon_analisis[
    (amazon_analisis["Category"]=="Copiers")
    & (amazon_analisis["Geography"]=="United States,Seattle,Washington")
].groupby("EmailID")["Profit"].agg(["sum"]).rename(columns={"sum" : "Total_Keuntungan"}).sort_values(by="Total_Keuntungan", ascending=False).head(5)
```

EmailID	Total_Keuntungan
RaymondBuch@gmail.com	6719.9808
FredHopkins@gmail.com	1480.4671
DanaKaydos@gmail.com	89.9970

Pelanggan dengan email RaymondBuch@gmail.com merupakan penyumbang keuntungan terbesar dari pembelian Copiers di United States, Seattle, Washington. Sehingga dapat disarankan untuk menjalankan bisnis B2B dengan pelanggan tersebut dan menjadi supplier utama produk berkategori Copiers

5. Insight

Insight

- **Nilai Sales Tinggi Namun Nilai Kerugian Juga Tinggi**

Saat menghitung jumlah kerugian, modal, dan sales pada transaksi yang rugi, kategori Tables memiliki jumlah kerugian terbesar meski jumlah sales yang terbesar juga. Hal ini terjadi akibat jumlah modal yang besar. Jika hal ini dibiarkan, maka perusahaan berpotensi menanggung kerugian untuk kedepannya.

- **Copiers Menjadi Kategori Pemberi Keuntungan Terbesar**

Copiers menghasilkan profit paling besar jika dibandingkan kategori lainnya. Namun jumlah kuantitas yang terjual masih lebih rendah daripada kategori lain. Sehingga masih dapat ditingkatkan lagi jumlah penjualan Copiers.

- **Seattle, Washington dan RaymondBuch Penghasil Keuntungan Terbesar dari Transaksi Copiers**

Keuntungan penjualan Copiers terpusat di lokasi Seattle, Washington. Email pelanggan yang menghasilkan keuntungan terbesar dilokasi tersebut adalah RaymondBuch@gmail.com

6. Recommendation

Recommendation

- **Evaluasi Harga Pada Kategori Yang Rugi (Khususnya Tables)**

Menekan nilai modal dan meningkatkan nilai sales sehingga transaksi yang merugi menjadi tidak rugi, namun tidak untung juga (Break Even) dalam waktu 4 bulan.

- **Evaluasi Kategori Copiers**

Di era digitalisasi, perlu adanya evaluasi kembali mengenai keuntungan Copiers di tahun terakhir. Dikhawatirkan produk Copiers sudah tidak relevan di era digitalisasi. Namun apabila masih relevan, maka dapat disarankan membentuk hubungan B2B ke pelanggan korporat/instansi yang membeli Copiers

- **Ekspansi B2B Khususnya pada Copiers Di Seattle, Washington**

Menjalin hubungan B2B dengan RaymondBuch@gmail.com dan pelanggan korporat/instansi lainnya di Seattle, Washington. Menjadi supplier Copiers utama di lokasi tersebut dan mendapat 3 klien B2B dalam waktu 3 bulan.

Terima Kasih